

MLOps 기말 프로젝트

다이캐스팅 정상/불량 예측을 위한 MLOps 기반 AI 서비스

End-to-End MLOps Pipeline for Die-Casting Defect Prediction

아주대학교 · MLOps · 8조

김병근 (Data) · Zhang Xin (Modeling/XAI) · 심재광 (MLOps/Serving)

2026-06-14

문제 정의와 목표

공정·센서 데이터로 제품의 **정상/불량**을 예측하고, 그 **판단 근거(XAI)**를 함께 제시하는 AI 서비스

배경

- 온도·압력·분사시간 등 다수 공정 변수가 품질에 영향
- 변수 간 상호작용이 복잡 → 사람의 직관만으로 일관된 판단 곤란
- 단순 성능 비교가 아닌 "운영 가능한 AI 서비스" 구축이 목표

입·출력 / 대상

대상 사용자	다이캐스팅 공정 엔지니어 / 품질관리자
입력 (Input)	28개 공정·센서 feature
출력 (Output)	정상/불량, 클래스 확률, 상위 기여 feature
성공 기준	F1/ROC-AUC · MLflow · API+UI · Docker

데이터 이해와 전처리

KAMP 다이캐스팅 Product 1 · binary_product1_v2_dedup

4,207 → 2,515

중복 1,692건 제거 후

1,960 / 555


정상 / 불량 (22.1%)

70 / 15 / 15

stratified split · overlap 0

전처리 핵심

- 이진 라벨: 결함 컬럼 합 > 0 → defect(1), 아니면 normal(0)
- 라벨 누출 방지: 결함 판정 26개 컬럼을 feature에서 제거
- 중복 제거 후 stratified 분할, 3분할 간 완전중복 0건 검증
- 결측치 0 · 상수 feature 8개 · EDA로 SMD 상위 8개 분석
- 최상위 분리 변수: Factory_Humidity (SMD 0.715, 불량과 음의 상관)



■ 정상(normal) ■ 불량(defect)

데이터 파이프라인 — DVC 4단계 실행

dvc repro 한 줄로 순서 실행 · 입력 해시가 바뀐 단계와 그 이후만 다시 실행(증분)

단계 · 실행 명령	처리 내용	산출물 (outs)
1 prepare_data python -m src.data.prepare_data	라벨 생성 → 결함 26컬럼 제거(누출 방지) → 중복 1,692건 제거 → stratified 70/15/15	train/valid/test.csv data_profile.json · EDA plots
2 train_binary python -m src.models.train_binary	RandomForest baseline 학습(balanced) validation-test 평가 + MLflow 로깅	rf_baseline.joblib 지표·플롯 · MLflow run
3 compare_baselines_xai python -m src.models.compare_baselines_xai	5개 후보 동일 split 비교 → Val F1 순위화 최적 후보에 SHAP 전역·지역 해석	baseline_comparison.json SHAP 산출물 · handoff note
4 tune_logistic python -m src.models.tune_logistic	5-fold CV 30회 탐색 → threshold sweep(0.49) → champion 등록·태깅	model.joblib · metadata.json metrics.json

각 단계의 산출물이 다음 단계의 입력이 되며, dvc.lock 해시로 정합성·증분 실행을 보장

MLOps 4계층 & 재현성

파이프라인을 떠받치는 도구의 역할과, 누구나 동일 결과를 얻는 방법

Git / GitHub

코드·설정 버전관리

작업 브랜치 sim → main 통합. .gitignore로 데이터·모델·DB는 제외 → 코드와 데이터의 책임을 분리

DVC

데이터·파이프라인 버전관리

content-addressed 캐시 + 4-stage DAG. dvc.lock 해시로 바뀐 단계만 증분 재실행, 어디서나 dvc pull로 복원

MLflow

실험 추적 · 모델 거버넌스

params·metrics·artifacts를 run 단위로 기록. champion 태그로 서빙 대상 단일화(이전 champion은 superseded)

Docker

환경 동결 서빙

runtime·의존성·champion 아티팩트를 추론 전용 image(~154MB)로 고정 → .venv 없이도 동일 추론

재현 절차 `git checkout` → `dvc pull` → `docker run`

코드(Git) + 데이터(DVC) + 모델 선택(MLflow) + 환경(Docker)이 맞물려 임의 시점 모델을 동일하게 재현

모델 실험 — 어떻게 비교했나

동일 split에서 5개 후보를 같은 절차로 학습·평가하고 validation F1로 순위화 (AutoML-lite)

1 동일 split 고정


2 5개 후보 학습

3 동일 지표 평가

4 Val F1 순위화

5 Champion 선정

결과: validation F1 순위



Champion: Logistic Regression

Val F1 **0.523** · Recall **0.819** · ROC-AUC **0.743**

선정 근거 (다음 단계 `tune_logistic`으로 핸드오프)

- 불량 탐지에 중요한 recall이 가장 높음
- 학습·추론 < 0.01s 로 가장 빠름
- 선형 모델 → 계수 기반 해석 용이
- 트리·부스팅 계열은 recall/F1 열세


튜닝 & 실험 추적 (MLflow)

5-fold CV 30회 탐색 → threshold 0.49 선택

구분	F1	ROC-AUC	Recall	Precision
Baseline val @0.50	0.523	0.743	0.819	0.384
Tuned val @0.49	0.534	0.748	0.843	0.391
Champion test @0.49	0.488	0.758	0.759	0.360

Best Params · Champion

C=0.0562 · penalty=l2 · solver=saga · class_weight=balanced
MLflow run: c902f8c099e941e6ba2d3dc62a4cf3b1
params-metrics-artifacts 기록 + champion 태그 (이전 champion은 superseded)



MLflow champion run

XAI — 모델 해석 (SHAP)

전역(global) + 지역(local) 해석으로 판단 근거 설명




그림: 평균 |SHAP| 상위 feature

전역 해석

- Factory_Humidity — 가장 큰 기여 (높을수록 정상)
- Spray_1_Time — 높을수록 불량
- SHAP·permutation·EDA(SMD) 결과가 상호 일치

지역 해석 (test sample #57)

실제=불량, 예측=불량, defect 확률 0.801

- Factory_Humidity=46.4 → SHAP +1.39 (불량 강하게 기여)
- 낮은 공장 습도가 핵심 동인 → 전역 해석과 일치
- 변수별 기여도로 "왜 불량인가"를 엔지니어에게 제시

Serving — FastAPI & Streamlit

REST API (FastAPI)

GET /health

모델 로드 상태 확인

GET /model-info

버전·threshold·feature 목록

POST /predict

예측·확률·상위 기여 feature

응답 구성:

예측 라벨 · 클래스 확률 · 상위 5개 기여 feature · 모델/데이터 버전
→ 추적성과 설명가능성 동시 제공

Streamlit UI · 6개 탭

Predict · Metrics · Data EDA · Feature Importance · Baseline/XAI · Artifacts

Diecasting Binary Defect Classification API

1.0.0 OAS 3.1

KAMP 다이캐스팅 공정/생산 데이터 기반 정상/불량 이진 분류 API

default

GET /health Health

GET /model-info Model Info

POST /predict Predict


Schemas

HTTPValidationError Expand all object

PredictionRequest Expand all object

PredictionResponse Expand all object

ValidationError Expand all object



>>

Deploy

Diecasting Defect Classification Dashboard

Predict Metrics Feature Importance Baseline/XAI Artifacts

Champion model: logistic_champion_v1 | Data: binary_defect_v2_devset

Model version	Data version	Feature count	Decision threshold
logistic_c...	binary_pr...	28	0.49

MLflow champion run: c902f3c09e9e54e8ba20d024c7302

Rows	Normal	Defect
2515	1960	555

Validation

ACCURACY	PRECISION	RECALL	F1	ROC-AUC
0.677	0.391	0.843	0.534	0.748

Docker 배포 & 재현성

~154 MB

추론 전용 image

healthy

volume 없이 실행

컨테이너 /predict 검증

- 정상 샘플 → normal (확률 0.8937)
- 불량 샘플 → defect (확률 0.6982)
- /health-/model-info 포함 4건 모두 HTTP 200

3단계 재현

1. git checkout
2. dvc pull
3. docker build & run

Diecasting Binary Defect Classification API 1.0.0 OAS 3.1

/openapi.json

KAMP 다이캐스팅 공정/센서 데이터 기반 정상/불량 이진 분류 API

default

GET	/health	Health	⌵
GET	/model-info	Model Info	⌵
POST	/predict	Predict	⌵

Schemas

HTTPValidationError	Expand all	object
PredictionRequest	Expand all	object
PredictionResponse	Expand all	object
ValidationError	Expand all	object

Docker 컨테이너 FastAPI Swagger

결론 & Future Work

F1 0.488

Test (recall 0.759)

ROC-AUC 0.758

Test 기준

9 / 9

평가 요구항목 충족

핵심 성과

- 데이터 버전관리 → 실험 추적 → 튜닝 → XAI → 서빙 → 컨테이너 배포 전 과정 구현·검증
- champion 모델은 불량 탐지(recall) 중심의 운영 가능한 baseline 제공
- git checkout + dvc pull + docker run 으로 환경 독립적 재현 보장

Future Work

- 데이터/예측 드리프트 모니터링 · 자동 재학습 트리거
- AutoGluon/H2O 본격 AutoML · 클라우드 registry/배포 · 멀티클래스 결함 분류